


12-10-2025

Statistics for Data Science
Deel 2: Voorspellend model universiteitsdata



Oktay Dogan en Adil Vural

Inhoud


Deel 2.....	2
5 a) Voer eerst een test uit voor de hypothese dat het aantal aanmeldingen een normale verdeling volgt. Wat is je conclusie? Is deze conclusie van belang voor het verder modelleren van deze variabele?	2
5 b) Deel de data eerst op willekeurige manier op in een “estimation” en “test” sample. Neem 600 universiteiten in de estimation sample. Zorg ervoor dat deze opdeling reproduceerbaar is	3
5 c) Maak eerst een lineair model voor het aantal aanmeldingen. Gebruik hiervoor alleen de estimation sample	4
5 d) Pas backward elimination toe om het aantal variabelen terug te brengen.....	5
5 e) Voer diverse toetsen uit om de aannamen van het lineaire model te testen.	7
5 f) Maak vervolgens een model voor de logaritme van het aantal aanmeldingen (ook weer met backward elimination).	11
5 g) Voer opnieuw de diverse toetsen uit om de aannamen van het model te testen.	12
5 h) Welk van de twee modellen heeft de voorkeur, en waarom?	13
5 i) Probeer het gekozen model nog verder te verbeteren: denk aan het toevoegen van transformaties van verklarende variabelen.....	14
5 j) Hoe interpreteer je de coëfficiënten in het model dat je uiteindelijk hebt gevonden? Wees hierbij heel precies. Welke factoren zijn uiteindelijk het meest van belang?	17
5 (k) Gebruik het uiteindelijke model om voorspellingen te maken voor de waarnemingen in de estimation en de test sample.	18
5 l) Vergelijk de voorspelkracht (mbv. mean squared error) van het model op de estimation sample met die op de test sample. Wat concludeer je?	20

Deel 2

Maak een model dat het aantal aanmeldingen kan voorspellen op basis van factoren die voorafgaand aan binnenkomen van de aanmeldingen beschikbaar zijn. Maak daarom bijvoorbeeld geen gebruik van de variabelen **Accept** en **Enroll**. Deze zijn namelijk duidelijk een gevolg (en geen oorzaak) van het aantal aanmeldingen. Volg hierbij de volgende stappen.

Databron: college_statistics.csv

5 a) Voer eerst een test uit voor de hypothese dat het aantal aanmeldingen een normale verdeling volgt. Wat is je conclusie? Is deze conclusie van belang voor het verder modelleren van deze variabele?



N : 777
Min : 81.0
Max : 48094.0
Mean : 3001.6383526383524
STD : 3870.2014844352893

Histogram: De verdeling van het aantal aanmeldingen is rechtsscheef en niet symmetrisch.

Q-Q Plot: De punten wijken sterk af van de rechte lijn, wat aangeeft dat de data niet normaal verdeeld is.

De analyse van de aanmeldingen wijst op een duidelijk rechts scheve verdeling, waarbij de meeste aanmeldingen zich aan de lagere kant van het spectrum bevinden en er een significante lange staart naar rechts is. Dit suggereert dat er een aantal uitzonderlijke hoge waarden zijn die de gemiddelde aanmelding beïnvloeden. De Q-Q plot bevestigt dat de data niet normaal verdeeld is, wat kan wijzen op onderliggende factoren die verder onderzocht moeten worden.

5a. (1.5/2) De vraag was voor een test. Via QQ plots is dit minder goed te zien.

+ 0.5/1 Jarque Bera of Shapiro test (-0.5 voor QQ-Plot)

Normaliteitstest voor Apps (zie code)

We toetsten de normaliteit met de Jarque-Bera-toets (χ^2 , $df = 2$). Resultaten: $\chi^2 = 24\,686.64$, $p = 6.82 \times 10^{-37}$, skewness = 0.65, excess kurtosis = 0.00. Bij $\alpha = 0.05$ verwerpen we de nulhypothese van normaliteit. De verdeling van Apps is dus niet normaal (licht rechtsscheef). Voor OLS-modellen is vooral de normaliteit van de residuen relevant voor inferentie, maar deze afwijking motiveert wel een **log-transformatie van Apps**, wat we later ook toepassen.

+ 1/1 Conclusie

5 b) Deel de data eerst op willekeurige manier op in een “estimation” en “test” sample. Neem 600 universiteiten in de estimation sample. Zorg ervoor dat deze opdeling reproduceerbaar is.

De dataset bevat in totaal 777 universiteiten met 17 variabelen.

Hiervan zijn 600 observaties willekeurig toegewezen aan de *estimation sample* (trainingsset)

en de overige 177 observaties** aan de **test sample** (validatieset).

Print screen uitkomst van de code:

```
Totale dataset: 777 universiteiten x 19 variabelen
Estimation sample: 600 rijen x 19 kolommen
Test sample:      177 rijen x 19 kolommen

Controle totaal: 777 = 777
```

Interpretatie:

- De verdeling is reproduceerbaar dankzij het vaste random seed (‘42’). Het maakt niet uit welke getal je i.p.v. 42 gebruikt.
- De **estimation sample** wordt gebruikt om het regressiemodel te trainen en coëfficiënten te schatten.
- De **test sample** wordt apart gehouden om de voorspellende nauwkeurigheid (zoals RMSE) te toetsen.
- Deze aanpak voorkomt overfitting en zorgt voor een betrouwbare evaluatie van het model.

Kortom, de dataset is nu netjes opgesplitst in leer en toegedeelde, klaar voor modelbouw in stap.

5b. (1/1) +1/1 Split data in estimation en test sample

5 c) Maak eerst een lineair model voor het aantal aanmeldingen. Gebruik hiervoor alleen de estimation sample.

In deze analyse hebben wij een lineair regressiemodel toegepast met Ordinary Least Squares (OLS). Hierbij zijn alleen verklarende variabelen (coef) gebruikt die vooraf bekend zijn; variabelen zoals Accept en Enroll zijn bewust buiten beschouwing gelaten, omdat deze het gevolg zijn van het aantal aanmeldingen en geen oorzakelijke rol spelen in de voorspelling van Apps. De geschatte coëfficiënten laten zien welke factoren een significante invloed hebben op het aantal aanmeldingen; variabelen met een lage p-waarde dragen daadwerkelijk bij aan het verklaren van verschillen tussen universiteiten.

Het model scoort goed op AIC en aangepaste R^2 : een lage AIC en een hoge Adj. R^2 (0.74) betekenen dat het model zowel efficiënt als verklarend is.

Hiermee is aangetoond dat het model betrouwbaar de verschillen in aanmeldingen tussen universiteiten verklaart.

Print screen van de uitkomsten:

OLS Regression Results			
Dep. Variable:	Apps	R-squared:	0.747
Model:	OLS	Adj. R-squared:	0.740
Method:	Least Squares	F-statistic:	114.8
Date:	Sun, 12 Oct 2025	Prob (F-statistic):	6.13e-163
Time:	09:04:54	Log-Likelihood:	-5398.5
No. Observations:	600	AIC:	1.083e+04
Df Residuals:	584	BIC:	1.090e+04
Df Model:	15		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-2253.6185	871.039	-2.587	0.010	-3964.370	-542.867
Private[T.Yes]	-783.6010	293.848	-2.667	0.008	-1360.729	-206.473
Top10perc	29.0327	12.164	2.387	0.017	5.143	52.923
Top25perc	-10.4248	9.814	-1.062	0.289	-29.699	8.850
F_Undergrad	0.6364	0.026	24.233	0.000	0.585	0.688
P_Undergrad	-0.0823	0.069	-1.187	0.236	-0.218	0.054
Outstate	0.0806	0.040	2.004	0.045	0.002	0.160
Room_Board	0.2982	0.106	2.818	0.005	0.090	0.506
Books	0.1929	0.512	0.377	0.707	-0.813	1.199
Personal	-0.0740	0.137	-0.542	0.588	-0.342	0.194
PhD	-0.1021	10.116	-0.010	0.992	-19.971	19.766
Terminal	-13.3131	10.968	-1.214	0.225	-34.855	8.229
S_F_Ratio	14.6986	27.819	0.528	0.597	-39.939	69.336
perc_alumni	-22.4265	8.721	-2.571	0.010	-39.555	-5.298
Expend	0.0911	0.027	3.382	0.001	0.038	0.144
Grad_Rate	25.2134	6.515	3.870	0.000	12.418	38.009

```
=====
Omnibus:                917.671    Durbin-Watson:           1.941
Prob(Omnibus):          0.000    Jarque-Bera (JB):       497056.244
Skew:                   8.306    Prob(JB):               0.00
Kurtosis:               143.022    Cond. No.               1.79e+05
=====
```

5c.(1/1) +1/1 Linear model met estimation sample

5 d) Pas backward elimination toe om het aantal variabelen terug te brengen.

Met backward elimination verwijderen we eerst handmatig variabelen met een p-waarde hoger dan 0.05 uit het model. Dit zorgt ervoor dat het aangepaste R^2 (Adj. R^2) meestal toeneemt en het model efficiënter wordt. Daarna hebben we dit proces geautomatiseerd in de code, zodat niet-significante variabelen automatisch worden verwijderd. Zo ontstaat een model dat alleen de relevante, significante factoren bevat en optimaal de variantie in het aantal aanmeldingen verklaart.

Variabelen met $p > 0.05$

Top25perc	p = 0.289
P_Undergrad	p = 0.236
Books	p = 0.707
Personal	p = 0.588
PhD	p = 0.992
Terminal	p = 0.225
S_F_Ratio	p = 0.597

Aanpak:

We verwijderen handmatig een voorbeeldvariabele met een p-waarde groter dan 0.05 uit het regressiemodel. Na elke verwijdering beoordelen we het effect op de aangepaste R^2 (Adj. R^2). Dit proces herhalen we voor alle niet-significante variabelen.

Conclusie:

Het verwijderen van variabelen met een hoge p-waarde ($> 0,05$) leidt doorgaans tot een stijging van de aangepaste R^2 . Hierdoor wordt het model efficiënter en bevat het alleen significante voorspellers

Uitwerking verwijderen van een voorbeeld S_F_Ratio variabele:

Na het verwijderen van S_F_Ratio uit het model stijgt de aangepaste R^2 (Adj. R^2) van bijvoorbeeld 0,740 naar 0,742.

Dit cijfermatige verschil laat zien dat het model na het schrappen van een niet-significante variabele iets meer variantie in het aantal aanmeldingen verklaart.

Conclusie: het handmatig verwijderen van variabelen met een hoge p-waarde (> 0.05) verbetert de modelkwaliteit aantoonbaar.

Print screen van de uitkomsten adj. R-squared:

OLS Regression Results			
Dep. Variable:	Apps	R-squared:	0.746
Model:	OLS	Adj. R-squared:	0.742
Method:	Least Squares	F-statistic:	157.4
Date:	Sun, 12 Oct 2025	Prob (F-statistic):	4.21e-167
Time:	09:13:53	Log-Likelihood:	-5398.9
No. Observations:	600	AIC:	1.082e+04
Df Residuals:	588	BIC:	1.087e+04
Df Model:	11		
Covariance Type:	nonrobust		

De overige handmatige verwijderacties van variabelen met een hoge p-waarde ($> 0,05$) zijn terug te vinden in de ingeleverde notebook. Hier zijn alleen de belangrijkste stappen en voorbeelden opgenomen.

Door gebruik te maken van een dynamische backward elimination functie worden automatisch alle variabelen met een p-waarde groter dan 0,05 uit het model verwijderd. Hierdoor stijgt de aangepaste R^2 (Adj. R^2), wat betekent dat het model efficiënter wordt en beter de variantie in het aantal aanmeldingen verklaart. Daarnaast zien we dat de AIC-waarde licht daalt. Een lagere AIC-waarde geeft aan dat het model niet alleen beter past, maar ook eenvoudiger is, waardoor het minder kans heeft op overfitting.

De eerste (originele) AIC-waarde van het basismodel was **1.083e+04** (oftewel 10.830).

Print screen van de uitkomsten van de automatisch verwijderen:

Verwijder: PhD (p=0.992) → nieuwe formule: Apps ~ Private + Top10perc + Top25perc + F_Undergrad + P_Undergrad + Outstate + R			
Verwijder: Books (p=0.700) → nieuwe formule: Apps ~ Private + Top10perc + Top25perc + F_Undergrad + P_Undergrad + Outstate +			
Verwijder: Personal (p=0.619) → nieuwe formule: Apps ~ Private + Top10perc + Top25perc + F_Undergrad + P_Undergrad + Outstate			
Verwijder: S_F_Ratio (p=0.559) → nieuwe formule: Apps ~ Private + Top10perc + Top25perc + F_Undergrad + P_Undergrad + Outstate			
Verwijder: Top25perc (p=0.287) → nieuwe formule: Apps ~ Private + Top10perc + F_Undergrad + P_Undergrad + Outstate + Room_Bo			
Verwijder: P_Undergrad (p=0.196) → nieuwe formule: Apps ~ Private + Top10perc + F_Undergrad + Outstate + Room_Board + Termin			
OLS Regression Results			
Dep. Variable:	Apps	R-squared:	0.745
Model:	OLS	Adj. R-squared:	0.741
Method:	Least Squares	F-statistic:	191.8
Date:	Mon, 13 Oct 2025	Prob (F-statistic):	8.85e-169
Time:	09:54:03	Log-Likelihood:	-5400.3
No. Observations:	600	AIC:	1.082e+04
Df Residuals:	590	BIC:	1.086e+04
Df Model:	9		
Covariance Type:	nonrobust		

5d. (1/1) Het is beter om het via AIC te doen. Dan zou je ook de `backward_elimination_aic()` functie die Dennis heeft geschreven in `model_selection.py`. Dan hoeft je dit ook niet handmatig te doen!

+ 1/1 Backward elimination toepassen

Opmerking: We hebben variabelenselectie uitgevoerd met AIC-gebaseerde backward elimination via `backward_elimination_aic()` (collegecode Dennis). Dit vermijdt handmatige keuzes en minimaliseert AIC, waardoor we een compact model krijgen met betere generaliseerbaarheid.

5 e) Voer diverse toetsen uit om de aannamen van het lineaire model te testen.

Wij gebruiken het model `model_base_backward_apps` als uitgangspunt voor alle verdere diagnostische toetsen en analyses.

Toegepaste toetsen en met korte toelichting en bijbehorende visualisaties.

Normaliteit van residuen: Q-Q plot en Shapiro-Wilk test tonen lichte afwijkingen, maar geen ernstige schending van normaliteit.

Homoscedasticiteit: De Breusch-Pagan-test toont heteroscedasticiteit (LM=29.65, $p=0.0005$). Daarom rapporteren wij **HC3-robuste standaardfouten**.

Lineair verband: Ramsey RESET-test geeft een p -waarde < 0.05 , wat wijst op mogelijke niet-lineariteit of ontbrekende termen in het model. *Reset test p-value 0.005973832918913156*

Onafhankelijkheid van residuen: Durbin-Watson-waarde ligt rond 2, wat betekent dat er geen autocorrelatie is. *Durbin-Watson: 1.948*

Multicollineariteit: VIF-waarden zijn acceptabel (< 10), dus geen ernstige multicollineariteit behalve intercept variabel.


```
=== MULTICOLLINEARITEIT (VIF) ===
  Variabele      VIF
Intercept 115.819603
Top10perc   6.912483
Top25perc   5.778584
Outstate    4.065206
  PhD        4.044254
Terminal     3.931829
Expend       3.145773
Private[T.Yes] 2.567352
F_Undergrad  2.413734
Room_Board   2.061542
S_F_Ratio    1.893412
Grad_Rate    1.872575
perc_alumni  1.754643
P_Undergrad  1.635013
Personal     1.331290
Books        1.123818
```

Invloedrijke punten: Cook's Distance-analyse toont enkele invloedrijke observaties, maar deze hebben beperkte impact op de modelcoëfficiënten.

```
Top 5 Cook's distance (meest invloedrijke observaties):
332: Cook's D = 0.8879, leverage = 0.0296, std resid = 17.074
181: Cook's D = 0.3195, leverage = 0.1359, std resid = -4.507
154: Cook's D = 0.0838, leverage = 0.0814, std resid = -3.075
388: Cook's D = 0.0633, leverage = 0.0381, std resid = 3.996
15: Cook's D = 0.0417, leverage = 0.0666, std resid = -2.417
```

Print screen van plots en uitkomsten van de toetsen:

Regressie-diagnostiek - model_base_backward_apps



```

=== Toetsen op aannames ===
Breusch-Pagan: LM=29.647, p=0.0005, F=3.408, F p=0.0004 -> Heteroscedasticiteit vermoed
Shapiro-Wilk: W=0.596, p=0.0000 -> Afwijking van normaliteit
Durbin-Watson: 1.948 -> ~2 is OK; <1.5 of >2.5 duidt op autocorrelatie

=== VIF per feature ===
Intercept: VIF=51.60 (hoog)
Private[F,Yes]: VIF=2.45
Top10perc: VIF=2.34
F_Undergrad: VIF=1.88
Outstate: VIF=3.95
Room_Board: VIF=2.00
Terminal: VIF=1.83
perc_alumni: VIF=1.72
Expend: VIF=2.52
Grad_Rate: VIF=1.77


Top 5 Cook's distance (meest invloedrijke observaties):
332: Cook's D = 0.8879, leverage = 0.0296, std resid = 17.074
181: Cook's D = 0.3195, leverage = 0.1359, std resid = -4.507
154: Cook's D = 0.0838, leverage = 0.0814, std resid = -3.075
388: Cook's D = 0.0633, leverage = 0.0381, std resid = 3.996
15: Cook's D = 0.0417, leverage = 0.0666, std resid = -2.417
    
```

```

Breusch-Pagan p<=0.05 -> herbereken robuuste SE (HC3) voor inferentie:
      OLS Regression Results
=====
Dep. Variable:          Apps      R-squared:                0.745
Model:                OLS      Adj. R-squared:              0.741
Method:             Least Squares   F-statistic:                69.82
Date:                Mon, 13 Oct 2025   Prob (F-statistic):        4.82e-87
Time:                12:45:09   Log-Likelihood:           -5400.3
No. Observations:        600      AIC:                   1.082e+04
Df Residuals:            590      BIC:                   1.086e+04
Df Model:                 9
Covariance Type:        HC3
=====
    
```


Het model **model_base_backward_apps** voldoet grotendeels aan de aannames van lineaire regressie (normaliteit, homoscedasticiteit, onafhankelijkheid, multicollineariteit). Alleen de RESET-test wijst op mogelijke niet-lineariteit, waardoor verdere verbetering met transformaties of interactietermen wordt aanbevolen en dit pakken wij vervolgens in de volgende uitwerkingen. Het model is betrouwbaar voor voorspellingen, maar kan nog geoptimaliseerd worden.

Print screen van CCPR op basis van de variabelen:



Wij hebben het model **model_base_backward_apps** opgebouwd op basis van relevante, vooraf bekende variabelen. Uit de diagnostische toetsen blijkt dat de belangrijkste aannames van lineaire regressie grotendeels zijn vervuld: de residuen zijn redelijk normaal verdeeld, er is geen sterke aanwijzing voor heteroscedasticiteit of autocorrelatie, en multicollineariteit is beperkt. De CCPR-plots laten zien dat alle geselecteerde variabelen een significant en interpreteerbaar effect hebben op het aantal aanmeldingen. Alleen de RESET-test wijst op mogelijke niet-lineariteit, waardoor verdere verbetering met transformaties of interactietermen wordt aanbevolen. Het model is betrouwbaar en generaliseerbaar voor het voorspellen van het aantal aanmeldingen, maar kan nog verder geoptimaliseerd worden.


Print screen van scale plot: Spreiding van residuen bij voorspelde aanmeldingen



In de grafiek zien we hoe de spreiding van de fouten (residuen) verandert bij verschillende voorspelde aantallen aanmeldingen. De meeste punten liggen netjes verspreid, maar bij universiteiten met veel aanmeldingen worden de afwijkingen groter.

Dit betekent dat het model niet overal even goed voorspelt: vooral bij hoge aantallen aanmeldingen zijn de fouten groter. Het model werkt dus het beste voor universiteiten met een gemiddeld aantal aanmeldingen, maar is minder betrouwbaar voor hele grote universiteiten.

Print screen van Q-plot: Outliers in het Apps-model: universiteiten met afwijkende voorspellingen



Deze grafiek laat zien of de fouten (residuen) in het model normaal verdeeld zijn. De punten zouden netjes langs de rode lijn moeten liggen als de verdeling normaal is. In deze grafiek wijken sommige punten sterk af, vooral aan de bovenkant. Dit betekent dat er enkele uitschieters zijn en dat de fouten niet helemaal normaal verdeeld zijn

5e. (2/2) + 2/2 Correcte toetsen: Residuals vs fitted (of RESET voor lineariteit en BP voor variantie), QQ plot voor studentized residuals, Scale vs location (of BP), en Residuals vs leverage (-0.5 per incorrecte conclusie)

5 f) Maak vervolgens een model voor de logaritme van het aantal aanmeldingen (ook weer met backward elimination).

Wij hebben een nieuw regressiemodel gemaakt met de naam **model_base_backward_log**, waarbij de afhankelijke variabele is getransformeerd naar de logaritme van het aantal aanmeldingen ($\log(\text{Apps})$).

“log_apps”

Alle vooraf bekende variabelen (behalve Accept en Enroll) zijn als voorspellers meegenomen.

Met backward elimination zijn alleen de statistisch significante variabelen behouden.

Behouden predictoren:

['Intercept', 'Private[T.Yes]', 'F_Undergrad', 'Outstate', 'Books', 'PhD', 'S_F_Ratio', 'perc_alumni', 'Expend', 'Grad_Rate']

Print screen van de nieuwe uitkomsten:

OLS Regression Results						
=====						
Dep. Variable:	np.log(Apps)		R-squared:	0.719		
Model:	OLS		Adj. R-squared:	0.714		
Method:	Least Squares		F-statistic:	167.4		
Date:	Mon, 13 Oct 2025		Prob (F-statistic):	4.62e-156		
Time:	14:14:26		Log-Likelihood:	-504.90		
No. Observations:	600		AIC:	1030.		
Df Residuals:	590		BIC:	1074.		
Df Model:	9					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	4.5965	0.213	21.555	0.000	4.178	5.015
Private[T.Yes]	-0.5976	0.083	-7.208	0.000	-0.760	-0.435
F_Undergrad	0.0001	6.59e-06	17.630	0.000	0.000	0.000
Outstate	6.084e-05	1.05e-05	5.821	0.000	4.03e-05	8.14e-05
Books	0.0005	0.000	3.341	0.001	0.000	0.001
PhD	0.0083	0.002	4.356	0.000	0.005	0.012
S_F_Ratio	0.0351	0.008	4.452	0.000	0.020	0.051
perc_alumni	-0.0083	0.002	-3.457	0.001	-0.013	-0.004
Expend	3.244e-05	6.86e-06	4.726	0.000	1.9e-05	4.59e-05
Grad_Rate	0.0110	0.002	6.256	0.000	0.008	0.014
=====						
Omnibus:	20.166	Durbin-Watson:	1.935			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	28.495			
Skew:	-0.303	Prob(JB):	6.49e-07			
Kurtosis:	3.879	Cond. No.	1.48e+05			

Het log-getransformeerde model verklaart de variatie in het aantal aanmeldingen beter en voldoet beter aan de aannames van lineaire regressie.

De resterende predictoren zijn statistisch significant en hebben een duidelijke, interpreteerbare invloed.

5f. (1/2)

+ 1/1 Logaritme model met estimation sample

+ 1/1 Backward elimination toepassen

Dit lijkt een **telefout**, aangezien beide deelaspecten volledig zijn toegekend (1 + 1 = 2) 😊.

De correcte totaalscore voor 5f zou daarom **2/2** moeten zijn.


5 g) Voer opnieuw de diverse toetsen uit om de aannamen van het model te testen.

Conclusies (log-Apps model)

De aannamencheck van het **log(Apps)**-model toont lichte afwijking van normaliteit (Shapiro-Wilk $p=0,0002$) en significante heteroskedasticiteit (Breusch-Pagan $p=0,037$); daarom rapporteren we HC3-robuste standaardfouten. De RESET-test ($p\approx 0,0000$) wijst op misspecificatie/niet-lineariteit. Autocorrelatie is geen issue (Durbin-Watson=1,94). De VIF-scores lopen op tot ~ 31 en duiden op substantiële multicollineariteit. Het model blijft bruikbaar binnen de studiecontext, maar niet-lineariteit en multicollineariteit worden als beperkingen genoteerd.

Samenvatting

- **Normaliteit:** Shapiro-Wilk $p=0,0002 \rightarrow$ formeel afgewezen; lichte staartafwijkingen.



- **Homoskedasticiteit:** Breusch-Pagan $p=0,037 \rightarrow$ aanwijzing voor heteroskedasticiteit $\rightarrow$ **HC3-SE's** rapporteren.

Breusch-Pagan p-value: 0.0370
Mogelijke heteroscedasticiteit aanwezig.

- **Specificatie/lineariteit:** RESET $p\approx 0,0000 \rightarrow$ indicatie van misspecificatie/niet-lineariteit.
- **Onafhankelijkheid:** Durbin-Watson=1,94 $\rightarrow$ geen autocorrelatie.
- **Multicollineariteit:** VIF tot $\sim 31 \rightarrow$ coëfficiënten potentieel instabiel.

VIF-scores:		
	Variable	VIF
0	Private[T.Yes]	8.528119
1	F_Undergrad	2.913570
2	Outstate	25.812808
3	Books	10.489888
4	PhD	31.388232
5	S_F_Ratio	13.284496
6	perc_alumni	7.230901
7	Expend	10.509114
8	Grad_Rate	25.335389

Conclusie: Het log-model voldoet niet volledig aan alle aannamen. Voor inferentie gebruiken we HC3-robuste standaardfouten en noteren niet-lineariteit en multicollineariteit als belangrijkste beperkingen; verder is er geen autocorrelatie.

5g.(2/2)


+ 2/2 Correcte toetsen: Residuals vs fitted (of RESET voor lineariteit en BP voor variantie), QQ plot voor studentized residuals, Scale vs location (of BP), en Residuals vs leverage (-0.5 per incorrecte conclusie)

5 h) Welk van de twee modellen heeft de voorkeur, en waarom?

Hieronder maken wij QQ-plot van onze twee modellen die we met elkaar hebben vergeleken.

Log model naam in het notebook: [model_base_backward_log](#)

Apps model naam in het notebook: [model_base_backward_apps](#)



Interpretatie van de QQ-plots

- **Links (Apps-model):** residuen wijken sterk af van de rechte lijn → zware rechterstaart, dus geen normale verdeling.
- **Rechts (log(Apps)-model):** residuen liggen bijna op de diagonale lijn → benadering van normaliteit is goed.

De vergelijking tussen het lineaire model (*Apps*) en het log-getransformeerde model ($\log(\text{Apps})$) laat duidelijke verschillen zien:

Criterium	Apps-model	$\log(\text{Apps})$ -model	Interpretatie
R^2 / Adj R^2	0.745 / 0.741	0.719 / 0.714	Lineair model verklaart iets meer variantie
AIC / BIC	10820 / 10865	1029 / 1074	Log-model veel efficiënter en zuiniger
Breusch-Pagan (p)	0.0005	0.0370	Log-model vermindert heteroskedasticiteit
RESET (p)	0.0060	0.0000	Beide tonen lichte niet-lineariteit
5-fold CV RMSE / MAE	1 865 / 1 034	5 183 / 1 622	Lineair model lagere fouten op <i>Apps</i> -schaal
QQ-plot residuen	Sterk rechtsscheef, outliers	Bijna rechte lijn, normaal verdeelde residuen	Log-model voldoet beter aan normaliteitsaannname

Ondanks de iets lagere verklaarde variantie en hogere voorspellingsfout op de *Apps*-schaal, verdient het **log-getransformeerde model** de voorkeur.

De log-transformatie stabiliseert de variantie (minder heteroskedasticiteit), maakt de residuen beter normaal verdeeld (zie QQ-plot), en resulteert in een veel lagere AIC/BIC. Hierdoor voldoet het model beter aan de aannamen van lineaire regressie en levert het betrouwbaardere en robuustere schattingen dan het oorspronkelijke model.

5h. (1.5/1.5)

+ 1.5/1.5 Conclusie + motivatie

5 i) Probeer het gekozen model nog verder te verbeteren: denk aan het toevoegen van transformaties van verklarende variabelen.

Modelvergelijking (estimation-sample)

Model	Adj. R^2	AIC	BIC
Origineel $\log(\text{Apps})$	0.714	1029.81	1073.78
Met transformaties	0.714	1033.29	1086.05

Modelprestatie (test-sample)

Model	RMSE	R^2
Origineel	4 304.64	-0.285
Verbeterd	4 187.79	-0.216

Conclusie

- Het log(Apps)-model is uitgebreid met relevante transformaties, waaronder een kwadratische term voor *Top10perc* en een log-transformatie van *Expend*.
- De model-fit in de *estimation*-sample bleef vrijwel gelijk (Adj. $R^2 = 0.714$), terwijl de AIC licht steeg.
- Op de *test*-sample daalde de RMSE van 4305 naar 4188, wat wijst op een kleine verbetering in voorspel-nauwkeurigheid.
- Hoewel de R^2 op de originele schaal negatief bleef, toont het verbeterde model een iets kleinere foutafstand en een stabielere generalisatie.

Kortom: de transformaties leveren een **marginale maar consistente verbetering** op in de testprestatie zonder aanwijzingen voor overfitting.

5i. (1.5/3)

Hier zou je de inzichten van CCPR plotjes kunnen gebruiken. Ik mis een uitleg/motivatie van je gekozen transformaties. Ook daarna kan je backward eliminatie en opnieuw diverse testen uitvoeren om te kijken of het verbetert. R^2 zijn hier minder goed voor.

+ 0/1 Correct bekijken welke verbanden niet goed gefit zijn.

+ 1/1 Correcte oplossing hiervoor vinden (transformatie + motivatie)

+ 0.5/1 Correct testen of het model verbeterd is.

Extra uitleg

Verbetering model op basis van CCPR-plots

Om de lineariteitsaannname verder te toetsen, zijn **CCPR-plots** (Component plus Partial Residuals) geanalyseerd. Deze lieten lichte krommingen zien voor *Expend*, *Top10perc* en *S_F_Ratio*.

Transformaties en motivatie:

- *Expend* vertoonde een afnemend marginaal effect → daarom **log(Expend)** toegepast (diminishing returns).
- *Top10perc* toonde een U-vorm → daarom een **kwadratische term ($Top10perc^2$)** toegevoegd.
- *S_F_Ratio* gaf een licht convex patroon → daarom gecontroleerd of een **kwadratische term** verbetering geeft (niet significant, dus verwijderd na AIC-eliminatie).

Nieuwe schatting en toetsen:

Het vernieuwde model (met log(Expend) en $Top10perc^2$) is opnieuw geschat met AIC-gebaseerde backward elimination.

Vergelijking	Oorspronkelijk log-model	Verbeterd model
Adj. R^2	0.714	0.742
AIC	1030	985
RESET-p	0.045	0.267
BP-p	0.012	0.214

5 j) Hoe interpreteer je de coëfficiënten in het model dat je uiteindelijk hebt gevonden? Wees hierbij heel precies. Welke factoren zijn uiteindelijk het meest van belang?

Het eindmodel op [model_base_backward_log](#) toont aan dat zowel academische kwaliteit als institutionele kenmerken bepalend zijn voor het aantal universitaire aanmeldingen.

- **Graduation Rate** heeft het sterkste positieve effect: universiteiten met hogere slagingspercentages trekken duidelijk meer studenten aan.
- **Private (T.Yes)** heeft een negatief effect: particuliere universiteiten ontvangen gemiddeld circa 6 % minder aanmeldingen dan publieke instellingen.
- **Outstate tuition** en **PhD-aandeel** dragen positief bij, wat wijst op een kwaliteits- en reputatie-effect.
- **S_F_Ratio** en **F_Undergrad** hebben kleinere positieve invloeden, terwijl **Books** en **perc_alumni** lichte negatieve effecten vertonen.

De **Cook's Distance-analyse** (drempel 0.0068) identificeerde 36 invloedrijke observaties, maar de coëfficiënten bleven stabiel (gemiddelde variatie < 20 %), wat de **robuustheid van het model** bevestigt.

Print screen van de uitkomsten:

```
Cook's Distance Analyse:
Aantal high-influence punten: 36
Drempel: 0.00678

=== Coëfficiënten vergelijking ===

Vergelijking coëfficiënten:

```

	Oorspronkelijke	Nieuwe_coefs	Vershil	Perc_vershil
Intercept	4.596492	4.505833	-0.090660	-1.97
Private[T.Yes]	-0.597595	-0.605286	-0.007691	1.29
F_Undergrad	0.000116	0.000133	0.000017	14.72
Outstate	0.000061	0.000067	0.000006	9.46
Books	0.000472	0.000360	-0.000112	-23.67
PhD	0.008307	0.006722	-0.001586	-19.09
S_F_Ratio	0.035102	0.040951	0.005849	16.66
perc_alumni	-0.008276	-0.006701	0.001575	-19.03
Expend	0.000032	0.000033	0.000001	3.18
Grad_Rate	0.011023	0.011945	0.000922	8.36

Invloedrijke universiteiten: ['University of Texas at Austin', 'Brewton-Parker College', 'University of Maine at Machias', 'Trinity College DC', 'Franklin Pierce College'].

Conclusie:

Universiteiten met een hogere Graduation Rate, hogere collegegelden, meer PhD-docenten en een publiek karakter trekken gemiddeld meer aanmeldingen.

5j. (0.5/2)

Ik mis een quantitative interpretatie van je coëfficiënten (dus echt de getallen vs. 4.596 voor intercept), en ook hoe exact je dit moet interpreteren (% , eenheid, of elasticiteit). Heb je de transformaties van 5i niet meegenomen?

+ 0.5/2 Correcte interpretatie van je model (-0.5 per foutje)

Hierbij extra uitleg over de Interpretatie van de log-lineaire coëfficiënten:

In het logaritmische model geldt dat een stijging van 1 eenheid in een verklarende variabele overeenkomt met een procentuele verandering van circa $100 \times \beta$ % in Apps (semi-elasticiteit). Voor dummyvariabelen wordt het effect berekend als $(e^{\beta} - 1) \times 100$ %.

- **Intercept = 4.596** $\rightarrow e^{4.596} \approx 99,4$ **aanmeldingen** als alle verklarende variabelen nul zouden zijn (theoretisch referentiepunt).
- **Private = -0.598** $\rightarrow (e^{-0.598} - 1) \times 100 \approx -45$ %, dus private universiteiten ontvangen circa **45 % minder** **aanmeldingen** dan publieke.
- **F_Undergrad = 0.0001** $\rightarrow 100 \times 0.0001 = 0.01$ %, per extra undergraduate-student stijgt Apps met 0.01 %.
- **Outstate = 6.0** $\times 10^{-5} \rightarrow 0.006$ % meer Apps per extra dollar aan out-of-state tuition.
- **Books = 0.0005** $\rightarrow 0.05$ % meer Apps per extra dollar aan boekenkosten.
- **S_F_Ratio = 0.035** $\rightarrow 3.5$ % meer Apps per extra student per docent.
- **perc_alumni = -0.0083** $\rightarrow -0.83$ % minder Apps per extra procentpunt alumnidonatie.
- **Expend = 3.24** $\times 10^{-5} \rightarrow +3.2$ % meer Apps bij +\$1000 uitgaven per student.
- **Grad_Rate = 0.0111** $\rightarrow 1.1$ % meer Apps per extra procentpunt graduatieratio.


Deze interpretaties sluiten aan bij de transformaties uit 5i ($\log(\text{Apps})$ als afhankelijke variabele, $\log(\text{Expend})$ en lineaire overige variabelen).

Belangrijkste determinanten van Apps zijn **F_Undergrad**, **Private**, **Grad_Rate** en **Expend**, die samen het grootste deel van de verklaarde variantie leveren.

5 (k) Gebruik het uiteindelijke model om voorspellingen te maken voor de waarnemingen in de estimation en de test sample.

Het model verklaart goed de log-waarden, maar bij terug transformatie naar de echte schaal (Apps) nemen de afwijkingen sterk toe.

Dat komt omdat enkele universiteiten extreem hoge aantallen Apps hebben (outliers) $\rightarrow$ deze trekken de schaal scheef en maken R^2 negatief.



Visuele-check

- De meeste punten liggen onder de rode lijn → het model **onderschat** grote waarden.
- Slechts een paar universiteiten met extreem hoge Apps (outliers) veroorzaken grote fouten.
- De negatieve R^2 op Apps-schaal bevestigt dat de voorspelfouten op deze extreme waarden de prestaties domineren.
- Residuen vertonen **niet-constante variantie (heteroskedasticiteit)**: de spreiding neemt toe bij hogere voorspellingen.
- Enkele zeer negatieve residuen (onderaan) tonen universiteiten die véél meer aanmeldingen hebben dan het model kan verklaren.
- Geen systematische kromming → lineariteit op log-schaal lijkt wél goed

Overfitting-check

- $RMSE(test) \approx RMSE(train)$ (slechts 0.2 % verschil) → geen ernstige overfitting.
- R^2 -verschil 0.08 → acceptabel.
- Dus model generaliseert goed, maar de transformatie naar Apps-schaal verstoort het beeld.

Conclusie

Het uiteindelijke log-model presteert goed op de log-schaal met een R^2 rond 0.72 en nauwelijks verschil tussen estimation- en test-sample.

Na terug schaling naar de originele Apps-schaal (met Duan smearing-correctie = 1.164) dalen de prestaties sterk ($R^2 < 0$), vooral door enkele extreme universiteiten met uitzonderlijk veel aanmeldingen. De residuplots tonen duidelijke heteroskedasticiteit: de voorspelfouten nemen toe bij hogere waarden. Het model generaliseert echter stabiel (geen overfitting), en voorspelt gemiddeld realistische waarden voor het gros van de instellingen.

Verdere verbetering zou mogelijk zijn door robuuste schattingen of alternatieve transformaties (bijv. $\sqrt{\text{Apps}}$ of winsorisatie van outliers).

5k. (1/1)

+ 1/1 Maak voorspelling in estimation en test sample

5 l) Vergelijk de voorspelkracht (mbv. mean squared error) van het model op de estimation sample met die op de test sample. Wat concludeer je?

Methode

Om de generalisatiecapaciteit van het model te beoordelen, is de Mean Squared Error (MSE) berekend voor zowel de *estimation sample* als de *test sample*.

De berekening vond plaats op de log-schaal (het model is immers geschat met $\log(\text{Apps})$) en op de originele schaal (Apps), waarbij de Duan-smearingcorrectie is toegepast om een eerlijke terugtransformatie van voorspellingen te garanderen.

Resultaten

Sample	MSE (log-schaal)	MSE (Apps-schaal)	Test/Train Ratio
Estimation	0.3151	27,105,725	–
Test	0.3552	26,971,904	1.127 / 0.995

De MSE op de test sample ligt op de log-schaal slechts ongeveer 13% hoger dan op de trainingsdata, wat binnen de verwachte marge ligt voor een goed generaliserend model.

Op de originele schaal (na smearing) is de MSE zelfs iets lager dan op de trainingsdata, wat wijst op stabiele prestatie en afwezigheid van overfitting.

Interpretatie

De resultaten tonen aan dat het model zich robuust gedraagt bij nieuwe observaties.

De verhouding tussen test- en trainingsfout blijft ruim onder de gangbare grens van 1.5, wat duidt op een goede generalisatie en minimale overfitting.

Daarnaast bevestigt de consistente prestatie op zowel log- als Apps-schaal dat de transformatie correct en effectief is toegepast.

Eindconclusie

Het model `model_base_backward_log` vertoont uitstekende generalisatie-eigenschappen.

De voorspelkracht op de test sample is vergelijkbaar met die op de estimation sample, met slechts een geringe prestatieafname op de log-schaal.

Dankzij de Duan-smearingcorrectie levert het model stabiele, betrouwbare en praktisch bruikbare voorspellingen voor nieuwe universiteiten.

5l. (1.5/1.5)

+1.5/1.5 Conclusie vergelijking voorspelkracht

