

Artificial Intelligence: Machine Learning for Business Analytics

Lecture 1: Introductie & Dimensie reductie

Michel van de Velden

BIG DATA



© marketoonist.com

BIG DATA

- Veel waarnemingen
- Veel variabelen

En dus:

- Potentieel veel waardevolle informatie

Hoe krijgen we die informatie uit de databrei!

Gebruik Statistiek!

BIG DATA

- Veel waarnemingen
- Veel variabelen

En dus:

- Potentieel veel waardevolle informatie

Hoe krijgen we die informatie uit de databrei!

Gebruik Data Science!

BIG DATA

- Veel waarnemingen
- Veel variabelen

En dus:

- Potentieel veel waardevolle informatie

Hoe krijgen we die informatie uit de databrei!

Gebruik Machine Learning!

BIG DATA

- Veel waarnemingen
- Veel variabelen

En dus:

- Potentieel veel waardevolle informatie

Hoe krijgen we die informatie uit de databrei!

Gebruik Business Analytics!

BIG DATA

- Veel waarnemingen
- Veel variabelen

En dus:

- Potentieel veel waardevolle informatie

Hoe krijgen we die informatie uit de databrei!

Gebruik Artificial Intelligence!

CHRIS ANDERSON SCIENCE 06.23.08 12:00 PM

THE END OF THEORY: THE DATA DELUGE MAKES THE SCIENTIFIC METHOD OBSOLETE

The end of theory

"We can stop looking for models. We can analyze the data without hypotheses about what it might show. We can throw the numbers into the biggest computing clusters the world has ever seen and let statistical algorithms find patterns where science cannot."

De oorzaak bestaat niet meer,
alleen nog **big data**

16/11/2016

Het vinden van patronen in miljoenen data is vruchtbaarder dan het speuren naar de oorzaak, schrijft *Chris van der Heijden*.

Dankzij computers kunnen we tientallen miljoenen gegevens ordenen en verwerken - veel meer dan waartoe het menselijk verstand in staat is. Een voorbeeld. Een van de wetenschappelijke voor mannen van Google publiceerde een paar weken voor het uitbreken van de Mexicaanse griep in het tijdschrift *Nature* een artikel waarin hij beweerde dat een griepvirus kan worden voorspeld. Immers, dagelijks worden miljarden zoekopdrachten op Google ingetikt. Door dit zoekgedrag te analyseren kan een inschatting worden gemaakt van de situatie van de zoekers. Verzamelen duizenden mensen in regio Y op hetzelfde moment informatie over eenzelfde 'griepfenomeen', dan weet je dat een dergelijke griep op uitbreken staat, ja zelfs wellicht dat er een epidemie op komt is.

Relaties en correlaties heet dat. Ze isoleren niet enkele willekeurige factoren ('oorzaken') uit het complexe geheel, maar laten het geheel in stand en wijzen op de relaties tussen elementen

ervan. Een dergelijk verband zegt veelal heel wat meer dan de zogenoemde oorzakelijkheid.

Ik geef nog maar eens het beroemde voorbeeld van Edward Lorenz: de vleugelslag van een vlin der in Brazilië kan een orkaan in Texas veroorzaken. Lorenz kwam tot deze uitspraak via een ingewikkelde berekening op een destijds dure computer. Tegenwoordig kan iedereen thuis, met een apparaatje van een paar honderd euro en één vinger, eenzelfde soort berekeningen maken.

Chaos blijkt er niet zoveel te zijn. Toeval evenmin. En ook oorzaken zijn verdwenen.

We kennen complexe systemen die patronen vertonen en die bijeengehouden worden door correlaties. Dankzij moderne media kunnen we die correlaties doorzien. Precies hetzelfde beweerden animisten en natuurreligieuzen uit verre tijden. Ja, zij deden dat in andere bewoordingen, op basis van andere uitgangspunten en met een ander doel. Maar toch.

2013 is het jaar van de Big data. Daarmee is het ook het jaar van het 'grote inzicht'. Oeroud spiksplinternieuws.

Chris van der Heijden is historicus en schrijver.



The end of theory

"But faced with massive data, this approach to science — hypothesize, model, test — is becoming obsolete. "

Bigger is better!



BIGGER IS BETTER

- Voorspellingen van verkiezingsuitslag.
- Lastig.
- Verleden is makkelijker.
- US 1936:
- The Literary Digest poll: 10 million vragenlijsten verstuurd, 2.3 million kwamen ingevuld terug.


BIGGER IS BETTER

- Voor wie het niet zo goed meer weet:

Landon




Roosevelt



- Literary digest: Landon wint met 370 (uit 631).
- N=2.3 miljoen!

BIGGER IS BETTER

- Oeps!



WAT VOOR BEWIJS HEBBEN WE NIET?

- Het is belangrijk te weten wat je wel en niet hebt:

WAT VOOR BEWIJS HEBBEN WE NIET?

- Het is belangrijk te weten wat je wel en niet hebt:

“Uit onderzoek onder betrokkenen bij gevechten in café’s bleek dat bij de gevechten met dodelijke afloop, de gevechten in 90% van de gevallen waren begonnen door de overledenen.” - Howard Wainer

Maar nu hebben we Artificial Intelligence!

Waarom computers het afleggen tegen peuterintuïtie

Kunstmatige intelligentie

Hoe kan het toch dat computers op bovenmenselijk niveau schaken en go spelen, maar qua gezond verstand nog niet in de buurt komen van driejarigen?

✍ Bennie Mols ⌚ 9 november 2018



(NRC Handelsblad 9/11/18)

"Een man met een stapel papier in zijn handen loopt naar een gesloten kast toe. In de hoek van de kamer kijkt een klein jongetje toe. De man botst tegen de kast op, doet een paar stappen terug, loopt weer naar voren en botst voor de tweede keer tegen de kast op. Weer doet hij een paar stappen terug. Dan loopt het jongetje naar de kast, opent de deuren en kijkt omhoog naar de man. De man loopt weer naar de kast en terwijl het jongetje omlaag kijkt naar een boekenplank, legt de man de stapel papier in de kast."

March 2016



Kunstmatige intelligentie?

"In the first three days AlphaGo Zero played 4.9 million games against itself in quick succession" (Wikipedia).

Een spelletje go duurt gemiddeld tussen 45-60 minuten.

Wie er echt zin in heeft kan dus zo'n 10 potjes go op een dag spelen.

Dat zijn 3650 potjes in een jaar. In 1000 jaar zit je dan nog steeds dik onder de eerste trainingsfase van de computer.

Natuurlijke stompzinnigheid

March 2016



Kunstmatige intelligentie?

February 2023

INNOVATION

AI loses to human being at Go after seven years of victories

Dus:

Laten we "theory" nog maar niet aan de kant schuiven.

Alle huidige kunstmatige intelligentie is gebaseerd op data. De methoden gebruiken data (dus: wat er is gebeurd) om te “voorspellen” wat er zou kunnen gebeuren. (Maar: ze gebruiken daarvoor dingen die al eens gebeurt zijn)

Er komt geen begrip aan te pas

Voor begrip:



MACHINE LEARNING: TERMINOLOGIE

- We kunnen twee soorten problemen/situaties onderscheiden:
 - Supervised
 - Non-supervised

SUPERVISED LEARNING

- Bij “supervised” is er sprake van een “afhankelijke”/“verklaarde”/“te voorspellen”/“te herkennen” uitkomst.
- Aan de hand van gegevens zoeken we een functie/recept/algorithm/procedure die de gegevens (onafhankelijke variabelen) relateerd aan een uitkomst.
- Bijvoorbeeld:
 - Een bepaalde klant zal niet in staat zijn een lening af te lossen.
 - Een tekst is geschreven door een man/vrouw/specifiek auteur.
 - Een bezoeker van een webwinkel koopt een produkt.
 - Het bedrag dat een bezoeker van een webwinkel uitgeeft.
 - Een huis wordt verkocht/gekocht voor een bepaalde prijs.
 - Een foto van een nummerbord hoort bij een bepaald nummerbord.

UNSUPERVISED LEARNING

- Bij “unsupervised” is geen sprake van een “afhankelijke”/“verklaarde”/“te voorspellen” uitkomst.
- We zoeken naar structuur/verbanden in de gegevens.
- Bijvoorbeeld:
 - Kunnen we klanten aan de hand van achtergrond gegevens onderverdelen in groepen “gelijksoortige” klanten.
 - Zijn bepaalde woordcombinaties typerend voor teksten van bepaalde auteurs.
 - Hoe worden verschillende merken beoordeeld aan de hand van verschillende beschrijvende attributen.

UNSUPERVISED LEARNING

We gaan beginnen met unsupervised learning:

1. Dimensie reductie:
 - PCA (interval data) (vandaag)
 - CA & MCA (categorische data)
2. Cluster analyse

DIMENSIE REDUCTIE

- Als we (heel) veel variabelen hebben dan is het lastig om het overzicht te behouden. Of te krijgen.
- Het zou mooi zijn als we kunnen volstaan met een kleinere set variabelen.
- Dimensie reductie methoden zoeken zo'n kleinere set.
- Er bestaan verschillende dimensie reductie methoden.
- De bekendste/meest gebruikte is “Principale Componenten Analyse” (PCA).
(Vaak zijn andere methoden variaties op PCA).

PCA



- Bij principale componenten analyse (PCA) zoeken we een lineaire combinatie van de oorspronkelijke variabelen die zoveel mogelijk van de oorspronkelijke variantie beschrijft.
- Volgende principale componenten doen dan hetzelfde voor de eerder onverklaarde variantie.
- De lineaire combinaties zijn “orthogonaal”: ze staan loodrecht op elkaar. In statistische terminologie: ze zijn onafhankelijk.
- In plaats van de oorspronkelijke variabelen, kunnen we kijken naar de PCAs: de lineaire combinaties van de oorspronkelijke variabelen.

PCA

- PCA kan ook anders uitgelegd worden:
- Beschouw iedere variabele in onze data set als een dimensie.
- Als er p variabelen zijn dan kunnen we iedere waarneming (iedere rij in onze data matrix) zien als een p -dimensionaal punt.
- Voor $p=2$ kun je de waarnemingen eenvoudig in een plaatje (spreidingsdiagram) weergeven.
- Voor $p=3$ wordt het lastiger maar het is nog steeds voorstelbaar.
- Daarna is het puur abstract.

PCA

- In een spreidingsdiagram kiezen we een x- en y-as die horizontaal en verticaal lopen.
- Maar, dat hoeft helemaal niet.



PCA


- We kunnen de assen draaien: roteren
- Dit kunnen we gebruiken om zoveel/zo goed mogelijk de verhoudingen/relaties in de data te zien
- We zoeken een "hoek"/"perspectief" die de data goed weergeeft
- PCA geeft een schatting van de oorspronkelijke p dimensionale data in k dimensies. (Waar k gekozen wordt door de gebruiker)
- Het is een schatting. Een projectie
- We verliezen informatie

PCA: VOORBEELD


Obs	V1	V2	V3
1	-0.663364	-5.849495	-14.92299
2	0.2654976	-2.644401	-6.747937
3	-7.036367	-4.015081	-10.22391
4	-7.28515	-5.216681	-13.28905
5	-6.736922	-4.669582	-11.89473
6	-1.235135	-4.705708	-12.00296
7	-1.344615	-3.133348	-7.990783
8	-9.992564	-5.101169	-12.98642
9	1.1982047	-2.77831	-7.092326
10	-3.255799	-6.044205	-15.41223

We hebben data ($n=300$) voor 3 variabelen: Hier zijn de eerste 10 waarnemingen.

We kunnen alle 300 waarnemingen in een 3d spreidingsdiagram weergeven.





PCA: VC



PCA: VOORBEELD

- PCA bepaalt rotatie zodanig dat de eerste dimensies de data “zo goed” mogelijk beschrijven.
- “Zo goed mogelijk” = Som van gekwadrateerde afstanden van de punten in de eerste k-dimensies, tot de vol dimensionele data (aantal kolommen) is zo klein mogelijk.



PCA

- PCA doen geeft:
- Lineaire combinaties van originele variabelen.
 - Dus, waar aanvankelijk iedere kolom staat voor een variabele, zijn de principale componenten een combinatie (een gewogen gemiddelde) van meerdere variabelen
- De elementen van de lineaire combinaties (de gewichten per variabele) worden ladingen (loadings) genoemd. Deze kunnen we gebruiken bij het interpreteren van de PCAs
- De coördinaten van de observaties t.o.v. de nieuwe assen worden vaak scores genoemd
- Door een beperkt aantal PCAs (dimensies) te kiezen is er sprake van een benadering van de data: We verliezen dus informatie

PCA: PRINCIPALE COORDINATEN

Eigenschappen:

- De afstanden tussen de coördinaten in de gereduceerde, k -dimensionale ruimte, benaderen de afstanden tussen de coördinaten in de volle ruimte optimaal (in kleinste kwadraten)
- De projecties van de coördinaten op de door de ladingen bepaalde assen geven benaderingen van de originele data
- PCA oplossingen kunnen soms gebruikt worden om een grafische weergave in laag-dimensionale ruimte te geven

PCA: VOORBEELD

- We hebben van alle VWO (en Gymnasia) scholen in NL de gemiddelde scores op het Centraal Examen, per vak
- Na weglaten van een aantal specifieke vakken (Latijn, Grieks en nog wat facultatieve vakken die maar op weinig scholen worden aangeboden), houden we in totaal 12 vakken over
- We gaan kijken naar de scholen waarvan we voor al deze 12 vakken een gemiddeld cijfer hebben

PCA: VOORBEELD

- We hebben van alle VWO (en Gymnasia) scholen in NL de gemiddelde scores op het Centraal Examen, per vak
 - Na weglaten van een aantal specifieke vakken (Latijn, Grieks en nog wat facultatieve vakken die maar op weinig scholen worden aangeboden), houden we in totaal 12 vakken over
 - We gaan kijken naar de scholen waarvan we voor al deze 12 vakken een gemiddeld cijfer hebben
- Kunnen we in plaats van de scores voor 12 vakken, volstaan met scores op samenstellingen (gewogen gemiddelden) van de 12 vakken?
 - Kan dat met (veel) minder dan 12 (zeg: 2 of 3) zonder dat we teveel informatie verliezen?
 - En, als we die dimensie reductie kunnen uitvoeren zonder teveel informatie te verliezen, kunnen we die samenstellingen dan ook interpreteren? (Hoe?)

PCA: VOORBEELD

Zo ziet een stukje van de data eruit:

rstudio																
	Naam	Plaats	NL	Fr	Du	En	Sp	Ge	Ak	WkAC	WkBD	Nk	Sk	Bi	Ec	
1	Het 4e Gymnasium	1013 AX Amsterdam	74.69	79.21	70.98	71.60	71.60	72.52	71.26	67.39	76.09	64.86	72.33	67.81	75.07	
3	Barlaeus Gymnasium	1017 RV Amsterdam	70.19	75.60	72.59	72.10	72.10	72.92	66.85	63.95	76.45	76.07	70.29	68.24	76.92	
4	Bernard Nieuwentijt College (Damstede)	1025 KM Amsterdam	71.07	71.87	66.44	66.69	66.69	63.30	56.64	63.88	61.90	68.97	68.54	63.84	62.62	
5	Bredero Lyceum	1031 CG Amsterdam	66.86	65.28	56.97	65.12	65.12	67.03	67.78	66.90	75.28	65.74	67.20	68.62	61.72	
6	Cartesius Lyceum (Espritscholen)	1052 XN Amsterdam	67.67	65.56	65.67	67.24	67.24	66.58	71.54	67.51	66.78	64.65	63.50	68.95	64.78	
7	Sg. Nieuw-West, Comenius Lyceum	1062 BJ Amsterdam	71.22	69.32	62.96	69.49	69.49	75.88	68.42	65.96	69.96	63.96	68.96	69.96	70.63	
8	Hervormd Lyceum West	1065 JX Amsterdam	69.34	63.28	58.82	67.37	67.37	71.28	72.05	76.74	67.78	62.21	71.82	65.31	62.28	
9	Calandlyceum	1068 NT Amsterdam	64.43	61.47	59.82	67.30	67.30	70.23	66.36	70.61	69.93	66.27	70.07	70.27	66.86	
10	MS Amsterdam, Montessori Lyceum Amsterdam	1071 ED Amsterdam	65.70	71.23	63.75	66.13	66.13	72.65	60.07	63.07	59.59	63.34	65.00	65.63	67.06	
11	Fons Vitae Lyceum	1071 SW Amsterdam	63.73	66.07	62.71	65.60	65.60	65.15	60.85	59.56	66.90	67.75	66.22	68.01	65.18	
12	Berlage Lyceum (Espritscholen)	1073 KJ Amsterdam	65.84	63.08	53.28	68.75	68.75	70.63	67.08	72.99	64.48	70.28	70.68	66.28	80.22	
13	Het Amsterdams Lyceum	1075 BJ Amsterdam	67.44	73.39	65.24	68.55	68.55	66.93	68.10	66.03	71.78	66.36	71.46	68.42	62.67	
14	Spinozalyceum	1076 BH Amsterdam	67.93	67.24	59.83	67.34	67.34	66.95	67.95	71.21	71.17	71.24	75.64	69.44	62.24	
15	Vrije School Noord Holland, locatie Geert Groote Coll...	1076 ED Amsterdam	64.10	73.07	71.97	69.46	69.46	68.47	63.60	60.60	80.57	75.50	76.83	74.02	62.43	
16	Sg. Amsterdam-Zuid (Gerrit van der Veen)	1077 DT Amsterdam	67.89	61.21	66.09	66.71	66.71	65.87	69.21	63.55	65.87	69.62	66.87	69.02	72.46	

Showing 1 to 16 of 492 entries



PCA: PYTHON

1.PCA_VWO_voorbeeld_class

We gaan een aantal libraries gebruiken:

```
#imports
import pandas as pd
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
import mpl_axes_aligner
import numpy as np
from factor_analyzer.rotator import Rotator
```

PCA: PYTHON

De data staan in vwodata.csv:

```
# Open the data  
df = pd.read_csv('data/vwodata.csv')  
print(df.head())
```

PCA: PYTHON

In Python vinden we een PCA functie in sklearn.decomposition:

```
from sklearn.decomposition import PCA
```

We kunnen PCA uitvoeren als:

```
pca = PCA()  
pca_out = pca.fit_transform(df)
```

Nu hebben we een object met de PCA geroteerde waarden

We moeten weten hoeveel dimensies toereikend zijn.

Om dat te doen is het handig om de verklaarde varianties te plotten

PCA: PYTHON

```
pca = PCA() # Number of components equal to number of features
pca_out = pca.fit_transform(df)
plt.plot(pca.explained_variance_, marker='o')
plt.xlabel('Principal Component')
plt.ylabel('Explained Variance Ratio')
plt.title('PCA Explained Variance')
```

Wat zien we?

PCA Explained Variance

PCA: P

```
pca = f
```

```
pca_out
```


```
plt.plot
```

```
plt.xlabel
```

```
plt.ylabel
```

```
plt.title
```

Wat zie



es

PCA: PYTHON

Wat zien we?

Op y-as varianties. Op x-as PCs

Misschien ook handig om numeriek output te zien:

```
# Print(summary (explained variance ratio))  
print(pd.DataFrame({  
    'Explained Variance Ratio': pca.explained_variance_ratio_,  
    'Cumulative Explained Variance': pca.explained_variance_ratio_.cumsum()  
}))
```

PCA: PYTHON

PCA zoekt lineaire combinaties die zoveel mogelijk variantie beschrijven.

We zien dat verklaarde variantie per PC afneemt.


Hoeveel dimensies zijn “goed”?

Lastig...

Een populaire manier is te kijken naar een “elleboog” in het plaatje van de varianties per PC.

PCA Explained Variance

PCA: P




Elleboog ?

En dan ?

Kies punt voor de elleboog!

Vanaf elleboog zijn de dimensies even "onbelangrijk"

PCA: P



Dus: 2 dimensies.
Daarna (dus vanaf
elleboog)
verklaren de
dimensies
“weinig”. Niet
nodig?

Maar: totaal
37.26% verklaarde
variantie.

Genoeg?

PCA: VOORBEELD

PCA geeft lineaire combinaties van de 12 variabelen.

De eerste lineaire combinatie beschrijft zoveel mogelijk van de aanwezige variantie.

De tweede beschrijft zoveel mogelijk van de resterende variantie.

Etc.

Voor iedere waarneming (=rij van je data) kun je, voor iedere PC, een “score” berekenen door de PC lineaire combinatie toe te passen op de waarneming.

Als je deze scores berekent voor de eerste twee PCs krijg je twee scores.

Die scores kun je zien als coördinaten en weergeven in een plaatje.

PCA: VOORBEELD

Dit kan in een zogenaamd biplot
Helaas heeft Python geen standaard functie hiervoor.
We moeten die dus maken

Gedoe

Michael Attard (<https://insidelearningmachines.com/biplot/>) heeft een functie gemaakt. Die hebben we een beetje aangepast.

PCA: VOORBEELD

De functie noemen we biplot:

```
# Biplot function: Needs scores, loadings and pca (for variances)
def biplot(dfScores: pd.DataFrame, dfLoadings: pd.DataFrame, pca) ->
    None:
```

Als input hebben, naast **pca** (de PCA informatie over verklaarde varianties) nodig:

- “scores”: Coordinaten voor de waarnemingen tov de principale componenten; het nieuwe assen-stelsel) geven
- “ladingen”: Gewichten van de variabelen voor de principale componenten. Deze bepalen de nieuwe richtingen (de rol van variabelen voor de nieuwe dimensies)

PCA: VOORBEELD

Dus:

```
# Collect PCA results in dataframes
```


```
dfScores = pd.DataFrame(pca_out, columns=[ 'PC'+str(i) for i in  
    range(1,df.shape[1]+1)])
```

```
dfLoadings =  
    pd.DataFrame(pca.components_, columns=df.columns, index=dfScores.columns)
```

```
#produce biplot
```


```
biplot(dfScores, dfLoadings, pca)
```

PCA: VOORBEELD



Wat zien we?

PCA: VOORBEELD




Wat zien we?

De blauwe punten zijn de waarnemingen (de scholen).
De rode “lijnen” zijn de vakken.

Hoe interpreteren we dit?


PCA: VOORBEELD



Wat zien we?

De ladingen (vakken) zijn weergegeven als lijn. Zij geven de gewichten van de vakken in de 2 dimensies.


PCA: VOORBEELD



Wat zien we?

Wat betekent het als twee vakken de zelfde “richting” hebben?

PCA: VOORBEELD




Wat zien we?

Wat betekent het als twee vakken de zelfde “richting” hebben?

Er is dan sprake van sterke samenhang: Hoog gemiddelde voor het ene vak gaat samen met hoog gemiddelde voor het andere vak.


PCA: VOORBEELD



Wat zien we?

Wat betekent het als twee vakken
“loodrecht” op elkaar staan?

PCA: VOORBEELD




Wat zien we?

Wat betekent het als twee vakken
“loodrecht” op elkaar staan?

Er is dan geen sprake van
samenhang:
Gemiddelde voor het ene vak
geeft geen enkele informatie over
gemiddelde voor het andere vak.

PCA: VOORBEELD




Wat zien we?

Wat zijn de grijze punten?

De punten voor de scholen geven aan waar de scholen zich t.o.v. elkaar bevinden wat betreft de examencijfers.

Wat betekent het als scholen dicht bij elkaar liggen?

PCA: VOORBEELD



Wat zien we?

Wat zijn de grijze punten?

De punten voor de scholen geven aan waar de scholen zich t.o.v. elkaar bevinden wat betreft de examencijfers.

Wat betekent het als scholen dicht bij elkaar liggen?

Vergelijkbare gemiddelde scoresverdeling voor de vakken.

PCA: US DATA

2.PCA_USA_class

Data on several socio economic and demographic indicators per county in de VS:

USA2016data.csv

Doe zelf PCA op US data:



PCA: US DATA

2.PCA_USA_class

Data on several socio economic and demographic indicators per county in de VS:

USA2016data.csv

Wat betekent het als we PCA op deze data doen?

Wat is er aan de hand?

PCA: VARIANTIE OF CORRELATIE

PCA: beschrijft variantie.

Variantie betreft variatie rond gemiddelde. We bekijken de data dus in afwijking van het gemiddelde.

Maar: Variantie hangt af van de meeteenheden.

Wat nu als je variabelen hebt die in verschillende eenheden worden gemeten?

Bijvoorbeeld:

- Variabele: Populatie in county
- Variabele: Verandering in populatie (in procent).

Wat kunnen we hier aan doen?

PCA: VARIANTIE OF CORRELATIE

We moeten de data eerst standaardiseren:

```
dfs = StandardScaler().fit_transform(df)
```

En dan PCA toepassen op de gestandaardiseerde data



PCA: DATA

Voor PCA moeten de variabelen als “interval” data geïnterpreteerd kunnen worden.

Dat wil zeggen: verschillen in waarden zijn betekenisvol en niet afhankelijk van de waarden. (Verskil 5 en 3 is hetzelfde als verschil 200 en 198).

PCA is niet geschikt voor de analyse van categorische gegevens.

Als we alleen categorische gegevens hebben kunnen we Multipele Correspondentie Analyse (MCA) gebruiken.

Daarover later meer

PCA: MEER DAN 2 DIMENSIES

- Als er meer dan 2 dimensies nodig zijn dan worden plaatjes lastig.
 - Voor 3 dimensies kunnen we nog wel wat proberen.
 - Voor 4 en hoger wordt het nog lastiger.
 - Wat dan?
-
- Kijk naar numerieke output.
-
- Laten we even terug gaan naar VWO data.
-
- Interpreteer de eerste 3 dimensies.
 - Hoe?

PCA: MEER DAN 2 DIMENSIES


- PCA vindt lineaire combinaties van de oorspronkelijke variabelen.
- Zo'n lineaire combinatie geeft dus voor iedere variabele een "gewicht"/"lading".
- Als een lading voor een bepaalde variabele nul is, dan betekent dat dat die variabele niet meetelt in de lineaire combinatie.
- Als een lading sterk verschilt van nul, dan is die variabele dus erg belangrijk voor de component.
- Let op: het teken kunnen we alleen relatief interpreteren.

PCA: MEER DAN 2 DIMENSIES

- Dus:
 - Ladingen van nul: geen rol
 - Ladingen sterk verschillend van nul: grote rol
 - Ladingen er tussenin: Lastig.
-
- Om ladingen te interpreteren zou het dus handig zijn als we veel nullen en eventueel grote (absoluut) waarden hebben en weinig waarden er tussenin.
-
- Daar kunnen we wat aan doen!


PCA: ROTATIE

- PCA is te zien als rotatie:



Links variëren de coördinaten voor beide dimensies behoorlijk.

Rechts zijn de nieuwe y-waarden bijna allemaal dicht bij nul.



PCA: ROTATIE

- De oplossing van PCA is te zien als een rotatie.
- Als we een k-dimensionele oplossing hebben dan is PCA oplossing te schrijven als:
 - UV' :
 - U: Scores: dit zijn de principale coördinaten t.o.v. het nieuwe assenstelsel V.
 - V: Loadings: Dit zijn gewichten/coëfficiënten in de lineaire combinaties.
- Voor interpretatie is het handig als de ladingen sterk gecorreleerd zijn met een klein aantal variabelen. (En: weinig gecorreleerd met de rest).

PCA: ROTATIE

- Als we V en U over dezelfde hoek roteren, verandert het product UV' niet.
- We kunnen dus een rotatie zoeken die voor V “makkelijke” waarden geeft.
- Er zijn veel methoden om dat te doen.
- Varimax is een veel gebruikte rotatie methode die als doel heeft ladingen groot (in absolute waarde) of juist zeer klein (nul) te krijgen.
- Door de PCA oplossingen te roteren is het mogelijk om dimensies te interpreteren aan de hand van de oorspronkelijke variabelen.

PCA: ROTATIE

3.PCA_USA_class

Hoe doen we rotatie in Python?

We moeten eerst het aantal dimensies selecteren:

```
# PCA with rotation
k = 3 # The number of components to be considered
pca = PCA(n_components=k, svd_solver="full", random_state=0)
pca.fit(df)
```

Vervolgens selecteren we de loadings en roteren die dmv Rotator (`from factor_analyzer.rotator import Rotator`):

```
loadings = pca.components_.T
rotator = Rotator(method="varimax") # Needed to get coordinates for observations
loadings_rot = rotator.fit_transform(loadings)
```

PCA: ROTATIE

De geroteerde loadings zetten we in een data frame:

```
load_rot_df = pd.DataFrame(loadings_rot, index=df.columns, columns=["RPC1",  
    "RPC2", "RPC3"])
```

Deze kun je bekijken

We zien veel kleine getallen. Dat is goed.

Het is vaak handig/overzichtelijk om de kleine waarden weg te laten.

```
# Print "salient" rotated loadings  
def pretty(df, cutoff):  
    return df.where(df.abs() >= cutoff, other="")
```

PCA: ROTATIE

```
# We can select a cutoff for showing loadings
# Loadings that are larger (in absolute value) than this value (cut), will be
  printed:
cut = 1/(len(load_rot_df)**0.5) # Sum of squared elements is 1. So, if all same
  size, each is 1/sqrt(number of variables)
# cut = 0.1      # Some arbitrary value
# print(cut)
print("\nRotated Loadings:\n", pretty(load_rot_df, cutoff=cut))
print("\nRotation Matrix:\n", pd.DataFrame(R, index=["PC1", "PC2", "PC3"],
  columns=["RC1", "RC2", "RC3"]))
```


PCA: ROTATIE

De rotatie matrix (`rotator`) is nodig als we ook willen weten wat de geroteerde coördinaten voor de waarnemingen zijn.

```
scores = pca_out[:, [1, 2, 3]]  
scoresrot = scores.dot(R)
```

Om een plaatje te maken kunnen we doen:

Maar: Rotatie is vooral nuttig als je numerieke output wilt/moet bekijken: Als er meer dan 2 dimensies nodig zijn.

PCA ROTATIE: VWO DATA

Laten we kijken of we kunnen roteren met VWO data.

Doe PCA:

- Kies aantal dimensies. Laten we er dit keer 3 nemen.
- Bekijk de ladingen
- Roteer en zie of interpretatie makkelijker is.



PCA:

- Samenvattend:
 - Dimensie reductie kan gebruikt worden om een aantal, liefst klein, samengestelde variabelen (PCAs) te vinden die de data goed beschrijven.
 - Interpretatie van de samengestelde variabelen kan verbeteren door gebruik te maken van een rotatie methode.
 - Voordeel van de gereduceerde set met samengestelde variabelen is dat deze kleiner is, wat rekenwerk kan vereenvoudigen, interpretatie mogelijk maakt en eventueel ook visualizatie mogelijk maakt.

PCA: OPDRACHT 1

- Gebruik PCA om een weergave te geven van 24 James Bond films.
- Data: JamesBond.csv
- Hierin staan de titels, jaar van uitkomst, budget, opbrengst VS, opbrengst wereld (beide gecorrigeerd voor inflatie), duur van de film en rating van Rotten Tomatoes (25/10/2021).



PCA: OPDRACHT 2

- Gebruik PCA om een weergave te geven van het politieke landschap aan de hand van stemwijzer data.
- Data: stemwijzer2023.csv en stemwijzer2025.csv
- Hierin staan de antwoorden van politieke partijen op 30 stellingen in 2023 en 2025.
- Let op: Als we PCA op deze data doen dan nemen we dus aan dat de getallen 0 tot 2 (oneens tot eens) als interval data te zien is. Dat het dus ratings zijn op een “mee eens” schaal.
- EXTRA: Kijk waar jij je, aan de hand van de stellingen, in het landschap bevindt.



PCA: OPDRACHT 3

Doe PCA op human values data: HVs2018_sample.csv

Dit is een sample van data afkomstig van de European Social Survey (ESS).

Dat is een groot internationaal onderzoek.

De data komen uit 2018.

Uit 21 landen.

Ik heb een sample genomen van 2000 waarneming.

De variabelen in de data zijn ratings op 21 vragen over "waarden"

De vragen staan in HumanValues_Descriptions.docx

Welke "vraag" (vragen) zou je kunnen beantwoorden met PCA? (Wat zou je kunnen bereiken met PCA)

Doe PCA.



PCA: OPDRACHT 4

- Data van voetballers in de eredivisie (seizoen 2013: voetballers.csv)
 - Marktwwaarden
 - Aantal wedstrijden
 - Duur contract
 - Lengte
 - Etc.
- Doe PCA op erediviesvoetballers data

