

Artificial Intelligence: Machine Learning for Business Analytics

Lecture 2: Dimensie reductie: PCA, CA & MCA

Michel van de Velden

PCA: OPDRACHT 1

- Gebruik PCA om een weergave te geven van 24 James Bond films.
- Data: JamesBond.csv
- Hierin staan de titels, jaar van uitkomst, budget, opbrengst VS, opbrengst wereld (beide gecorrigeerd voor inflatie), duur van de film en rating van Rotten Tomatoes (25/10/2021).



0.JamesBond.ipynb

PCA: OPDRACHT 2

- Gebruik PCA om een weergave te geven van het politieke landschap (2025) aan de hand van stemwijzer data.
- Data: stemwijzer2025.csv
- Hierin staan de antwoorden van politieke partijen op 30 stellingen.
- Let op: Als we PCA op deze data doen dan nemen we dus aan dat de getallen 0 tot 2 (oneens tot eens) als interval data te zien is. Dat het dus ratings zijn op een “mee eens” schaal.
- EXTRA: Kijk waar jij je, aan de hand van de stellingen, in het landschap bevindt.



1.PCA_stemwijzer.ipynb

PCA: OPDRACHT 3

- Doe PCA op human values data: HVs2018_sample.csv
- Dit is een sample van data afkomstig van de European Social Survey (ESS).
- Dat is een groot internationaal onderzoek.
- De data komen uit 2018.
- Uit 21 landen.
- Ik heb een sample genomen van 2000 waarneming.
- De variabelen in de data zijn ratings op 21 vragen over "waarden"
- De vragen staan in HumanValues_Descriptions.docx
- Doe PCA.



2.HV.ipynb

PCA: OPDRACHT 4

- Doe PCA op erediviesvoetballers data: voetballers.csv
- Data van voetballers in de eredivisie (seizoen 2013)
 - Marktwaarden
 - Aantal wedstrijden
 - Duur contract
 - Lengte
 - Etc.



PCA: HUMOR DATA

- Humor data:
- Martin, R. A., Puhlik-Doris, P., Larsen, G., Gray, J., & Weir, K. (2003). Individual differences in uses of humor and their relation to psychological well-being: Development of the Humor Styles Questionnaire. *Journal of Research in Personality*, 37, 48-75.
- De variabelen Q1 tot Q32 betreffen uitspraken die op een 5-puntsschaal zijn beoordeeld waar 1=Nooit of bijna nooit waar, 2=zelden waar, 3= soms waar, 4= regelmatig waar, 5=altijd of bijna altijd waar (-1=geen antwoord).
- Een aantal van de uitspraken zijn:

PCA: VOORBEELD HUMOR


- Q1. I usually don't laugh or joke around much with other people.
- Q2. If I am feeling depressed, I can usually cheer myself up with humor.
- Q3. If someone makes a mistake, I will often tease them about it.
- Q4. I let people laugh at me or make fun at my expense more than I should.
- Q5. I don't have to work very hard at making other people laugh; I seem to be a naturally humorous person.
- Q6. Even when I'm by myself, I'm often amused by the absurdities of life.
- Q7. People are never offended or hurt by my sense of humor.
- Q29. I usually can't think of witty things to say when I'm with other people.
- Q30. I don't need to be with other people to feel amused; I can usually find things to laugh about even when I'm by myself.
- Q31. Even if something is really funny to me, I will not laugh or joke about it if someone will be offended.
- Q32. Letting others laugh at me is my way of keeping my friends and family in good spirits.

PCA: VOORBEELD HUMOR

- Als we PCA doen op de correlatie krijgen we de volgende resultaten.

PCA: VOORBEELD HUMOR


PCA Explained Variance (Humor Data)



Aan de hand van de "varianties" per dimensie kunnen we kiezen hoeveel dimensies nodig zijn. Als PCA op correlaties is gedaan, zou je kunnen kijken naar dimensies die meer dan "gemiddeld" verklaren. Bij analyse op correlatie is het gemiddelde altijd 1.

Dus: Kies dimensies met std (var) > 1.

Humor PCA Biplot (PC1 vs PC2)



Label	Statement	Humor style	Original question code
AF1	I usually don't laugh or joke around much with other people.	Affiliative humor	Q1
AF2	I don't have to work very hard at making other people laugh, I seem to be a naturally humorous person.	Affiliative humor	Q5
AF3	I rarely make other people laugh by telling funny stories about myself.	Affiliative humor	Q9
AF4	I laugh and joke a lot with my closest friends.	Affiliative humor	Q13
AF5	I usually don't like to tell jokes or amuse people.	Affiliative humor	Q17
AF6	I enjoy making people laugh.	Affiliative humor	Q21
AF7	I don't often joke around with my friends.	Affiliative humor	Q25
AF8	I usually can't think of witty things to say when I'm with other people.	Affiliative humor	Q29
SE1	If I am feeling depressed, I can usually cheer myself up with humor.	Self-enhancing humor	Q2
SE2	Even when I'm by myself, I'm often amused by the absurdities of life.	Self-enhancing humor	Q6
SE3	If I am feeling upset or unhappy, I usually try to think of something funny about the situation to make myself feel better.	Self-enhancing humor	Q10
SE4	My humorous outlook on life keeps me from getting overly upset or depressed about things.	Self-enhancing humor	Q14
SE5	If I'm by myself and I'm feeling unhappy, I make an effort to think of something funny to cheer myself up.	Self-enhancing humor	Q18
SE6	If I am feeling sad or upset, I usually lose my sense of humor.	Self-enhancing humor	Q22
SE7	It is my experience that thinking about some amusing aspect of a situation is often a very effective way of coping with problems.	Self-enhancing humor	Q26
SE8	I don't need to be with other people to feel amused I can usually find things to laugh about even when I'm by myself.	Self-enhancing humor	Q30
AG1	If someone makes a mistake, I will often tease them about it.	Aggressive humor	Q3
AG2	People are never offended or hurt by my sense of humor.	Aggressive humor	Q7
AG3	When telling jokes or saying funny things, I am usually not very concerned about how other people are taking it.	Aggressive humor	Q11
AG4	I do not like it when people use humor as a way of criticizing or putting someone down.	Aggressive humor	Q15
AG5	Sometimes I think of something that is so funny that I can't stop myself from saying it, even if it is not appropriate for the situation.	Aggressive humor	Q19
AG6	I never participate in laughing at others even if all my friends are doing it.	Aggressive humor	Q23
AG7	If I don't like someone, I often use humor or teasing to put them down.	Aggressive humor	Q27
AG8	Even if something is really funny to me, I will not laugh or joke about it if someone will be offended.	Aggressive humor	Q31
SD1	I let people laugh at me or make fun at my expense more than I should.	Self-defeating humor	Q4
SD2	I will often get carried away in putting myself down if it makes my family or friends laugh.	Self-defeating humor	Q8
SD3	I often try to make people like or accept me more by saying something funny about my own weaknesses, blunders, or faults.	Self-defeating humor	Q12
SD4	I don't often say funny things to put myself down.	Self-defeating humor	Q16
SD5	I often go overboard in putting myself down when I am making jokes or trying to be funny.	Self-defeating humor	Q20
SD6	When I am with friends or family, I often seem to be the one that other people make fun of or joke about.	Self-defeating humor	Q24
SD7	If I am having problems or feeling unhappy, I often cover it up by joking around, so that even my closest friends don't know how I really feel.	Self-defeating humor	Q28
SD8	Letting others laugh at me is my way of keeping my friends and family in good spirits.	Self-defeating humor	Q32

PCA: PERSOONLIJKHEIDSTEST

- Ik heb data met antwoorden van 600 personen op 20 vragen van een persoonlijkheidstest.
- De data staan in: `personalitydata.csv`
- De vragen staan in het document: `personalitytest20items.txt`

PCA: PERSOONLIJKHEIDSTEST

- Ik heb data met antwoorden van 600 personen op 20 vragen van een persoonlijkheidstest.
- De data staan in: `personalitydata.csv`
- De vragen staan in het document: `personalitytest20items.txt`
- Doe PCA.



- Gebruik: Big 5 persoonlijkheidstest om je resultaten te duiden.

PCA: PERSOONLIJKHEIDSTEST

- Ik heb data met antwoorden van 600 personen op 20 vragen van een persoonlijkheidstest.
- De data staan in: personalitydata.csv
- De vragen staan in het document: personalitytest20items.txt
- Doe PCA.



- Gebruik: Big 5 persoonlijkheidstest om je resultaten te duiden.
- Big 5: openness, conscientiousness, extraversion, agreeableness, and neuroticism

Big 5: openness, conscientiousness, extraversion, agreeableness, and neuroticism

1. I am rarely sad or depressed.
2. I am a cheerful and well-disposed person.
3. Poetry says little or nothing to me.
4. I tend to think the best of other people.
5. I am efficient and effective in my work.
6. I often feel helpless, wanting someone to solve my problems for me.
7. I often feel like I am bursting with energy.
8. Sometimes when reading poetry and looking at a work of art I feel a shiver or a wave of emotion.
9. My first reaction is to trust other people
10. I am a very competent person.
11. I rarely feel lonely or depressed.
12. I am a very active person.
13. I find philosophical discussions boring
14. Some people consider me cold and calculating.
15. I strive to excel in everything I do.
16. There were times when I experienced resentment and bitterness.
17. I am dominant, full of strength and combative.
18. I do not attach much importance to things of art and beauty.
19. I tend to doubt the good intentions of others.
20. I am a practical person, always managing to do my job.

DIMENSIE REDUCTIE: CATEGORISCHE VARIABELEN

- PCA kan gebruikt worden bij interval data.
- Wat als we categorische gegevens hebben?
- Bijvoorbeeld:
 - Manier om naar werk te komen (auto, trein, bus etc.)
 - Nationaliteit
 - Geslacht
 - Ge-“like”de Facebookpagina
 - Aantal keer dat bepaald woord voorkomt in tekst.
 - Etc.

DIMENSIE REDUCTIE: CATEGORISCHE VARIABLEN

- Laten we eenvoudig beginnen:
- Twee categorische variabelen.
- We kunnen de samenhang tussen twee categorische variabelen middels een kruistabel bestuderen.
- (In excel wordt dan vaak gesproken over "pivot" tables).
- Laten we aan de hand van een voorbeeld kijken hoe dat werkt.

DIMENSIE REDUCTIE: CATEGORISCHE VARIABELEN

- De European Social Survey: www.europeansocialsurvey.org is een internationale survey die voorkeuren, gedrag, waardes etc. in een groot aantal landen meet.
- Steekproeven worden hiervoor gebruikt.
- Regelmatig worden nieuwe vragenlijsten verstuurd.
- De data zijn gratis te vinden op de website.
- Er is heel veel.
- Het is verstandig om eerst na te denken over wat je wilt onderzoeken.
- Wij gaan kijken naar Nederlandse data uit 2018.

DIMENSIE REDUCTIE: CATEGORISCHE VARIABELEN

- Laten we kijken naar wat mensen hebben gestemd en hoe gelukkig ze zijn:
 - Wat heeft u gestemd bij de laatste verkiezingen?
 - Hoe gelukkig bent u? (0- helemaal niet, 10-heel gelukkig)

	<4	5-6	7	8	9	10
50+	0	2	2	5	5	1
CDA	3	8	26	74	24	13
CU	1	1	6	15	10	3
D66	2	2	29	76	48	6
GL	0	7	9	34	8	5
PvdA	6	12	47	86	57	11
PvdD	1	1	8	17	4	2
PVV	5	14	24	32	18	9
SGP	0	1	6	9	3	3
SP	3	8	21	44	21	3
VVD	3	10	31	124	77	26

Er waren weinig mensen met lage scores. Daarom zijn <4 en 5 en 6 samengevoegd.

- Met Correspondentie Analyse (CA) kunnen we de gegevens in deze tabel visualizeren.

DIMENSIE REDUCTIE: CATEGORISCHE VARIABELEN

- In CA zoeken we “scores”/“coordinaten” voor alle categorieën.
- Dat gebeurt op zo’n manier dat wanneer de verdeling over de categorieën hetzelfde is, de scores (coordinaten) exact hetzelfde zijn.
- Kleine verschillen in de verdelingen leidt tot kleine verschillen in de coordinaten (=dichtbij elkaar in plaatje).
- Grote verschillen in de verdelingen leidt tot grote verschillen in coordinaten (=grote afstand in plaatje).

DIMENSIE REDUCTIE: CA

	<4	5-6	7	8	9	10
50+	0	2	2	5	5	1
CDA	3	8	26	74	24	13
CU	1	1	6	15	10	3
D66	2	2	29	76	48	6
GL	0	7	9	34	8	5
PvdA	6	12	47	86	57	11
PvdD	1	1	8	17	4	2
PVV	5	14	24	32	18	9
SGP	0	1	6	9	3	3
SP	3	8	21	44	21	3
VVD	3	10	31	124	77	26

- We gaan zien:
 - Hoe de verdeling over mate van "geluk" verschilt voor de stemmers op verschillende partijen.
 - Hoe de verdeling over de partijen is voor de groepen met verschillende mate van geluk.
 - En: De relatie tussen wat gestemd wordt en hoe gelukkig men is.

DIMENSIE REDUCTIE: CA

We gebruiken:

```
import prince
```

Daar is een functie voor CA te vinden:

```
# Perform Correspondence Analysis
```

```
ca = prince.CA(n_components=2)
```

```
ca = ca.fit(df)
```

	<4	5-6	7	8	9	10
50+	0	2	2	5	5	1
CDA	3	8	26	74	24	13
CU	1	1	6	15	10	3
D66	2	2	29	76	48	6
GL	0	7	9	34	8	5
PvdA	6	12	47	86	57	11
PvdD	1	1	8	17	4	2
PVV	5	14	24	32	18	9
SGP	0	1	6	9	3	3
SP	3	8	21	44	21	3
VVD	3	10	31	124	77	26


Om de resultaten weer te geven hebben we een functie `ca_plot` gemaakt:

```
from functions.ca_mca_plot import ca_plot
```


```
# Plot results
```

```
ca_plot(ca, df)
```

Correspondence Analysis: Voting & Happiness



Correspondence Analysis: Voting & Happiness



Net als bij PCA, kun je bij CA per dimensie zien hoeveel variantie verklaard is:
Hier: dim1, 50.20%, dim 2, 23.57%.
Bij elkaar dus rond de 75% verklaarde variantie.

Interpretatie?

DIMENSIE REDUCTIE: CA

- Met CA kun je kruistabellen visualizeren.
- Een kruistabel geeft in principe slechts de associatie weer tussen twee categorische variabelen.
- Wat als er meer categorische variabelen zijn?
- Je kunt dan meerdere tabellen maken en die allemaal apart analyseren.
- Het zou ook fijn zijn als we de relaties tussen meerdere categorische variabelen in een keer kunnen beschrijven.
- Dat kan: Multipiele Correspondentie Analyse (MCA).

DIMENSIE REDUCTIE: MCA

- MCA is in feite (=wiskundig gezien) hetzelfde als CA maar dan toegepast op een zogenaamde (super)indicator matrix.
- Een (super)indicator matrix:
 - Rijen zijn waarnemingen
 - Iedere kolom staat voor een categorie van een van de variabelen.
 - In de (super) indicator matrix staan alleen 1-en en 0-en. De 1 geeft aan dat de categorie is geselecteerd.

DIMENSIE REDUCTIE: MCA

- Een (super)indicator matrix:
 - Bijvoorbeeld: 10 waarnemingen, 3 variabelen: partij, vertrouwen, geslacht:(nepdata)

CDA	VVD	PvdA	PVV	Geen vertrouwen	Beetje vertrouwen	Veel vertrouwen	Vrouw	Man
1	0	0	0	1	0	0	1	0
0	1	0	0	0	1	0	1	0
0	1	0	0	0	0	1	0	1
0	0	1	0	0	0	1	0	1
0	0	1	0	0	1	0	1	0
1	0	0	0	1	0	0	0	1
0	0	0	1	1	0	0	0	1
0	0	0	1	0	1	0	0	1
0	0	0	1	0	1	0	1	0

DIMENSIE REDUCTIE: MCA

- Bij CA ligt de nadruk meestal op visualizatie.
 - In MCA is er dus ook grote nadruk op visualizatie.
 - Dat kan door weinig dimensies (liefst 2) te kiezen voor de scores:
 - We gaan de scores voor categorieën (en, soms ook voor individuen) vervolgens in een plaatje zetten:
 - Categoriepunten die dicht bij elkaar liggen, hangen dan sterk samen: ze worden relatief vaak tegelijk gekozen.
 - Etc.
-
- Laten we aan de hand van een voorbeeld zien hoe het werkt.

MCA: VOORBEELD

Ik heb voor ESS data van NL in 2018 een aantal variabelen netjes naast elkaar gezet:

```
# Load your data
df = pd.read_csv("data/ESS2018_mcadata.csv")
print("Original Data Preview:\n", df.head())
```

We gaan niet alle variabelen gebruiken. We selecteren eerst een aantal. Bijvoorbeeld:

```
select = ["prtvtfnl", "gndr", "domicil", "edulvla"]
```

Nu doen we MCA:

```
mca = prince.MCA(n_components=2)
mca = mca.fit(df[select])
```

MCA: VOORBEELD

We kunnen de MCA resultaten op vele manieren weergeven


Visualizatie is het doel, dus laten we plaatjes maken:

```
from functions.ca_mca_plot import ca_plot, mca_plot
```

We hebben dan een mca_plot functie die onze resultaten mooi kan visualizeren:

```
mca_plot(mca, df[select], title = "ESS data")
```

MCA Plot: ESS data



Wat valt op?

Ezraus

MCA: VOORBEELD

We kunnen de MCA resultaten op vele manieren weergeven

Visualizatie is het doel, dus laten we plaatjes maken:

```
from functions.ca_mca_plot import ca_plot, mca_plot
```


De mca_plot functie:

```
mca_plot(mca, df[select], title = "ESS data")
```

Het is ook mogelijk om de rijen (in dit geval: observaties) te plotten:

```
mca_plot(mca, df[select], title = "ESS data", plot= "both")
```


MCA Plot: ESS data



MCA: VOOF

We kunnen de N

Visualizatie is he

from functio

De mca_plot fur

mca_plot(mca

Het is ook moge

mca_plot(mca

OPDRACHT 0: EL PAIS

Het bestand “ElPaisTable.RData” bevat een tabel met verdelingen van vrijetijdsbesteding in verschillende landen (ik heb de tabel uit Greenacre, 2010).

Doe correspondentie analyse en interpreteer de resultaten



OPDRACHT 1: ESS

- Gebruik de ESS data (het data frame voor mca) en doe:
 - CA (selecteer 2 variabelen, maak een kruistabel)
 - MCA (selecteer meer dan 2 variabelen)



OPDRACHT 2: GAMES

In het bestand: “games_desc.Rdata” staat onder andere de kruistabel “cont_table_desc.Rdata” . Deze table heeft als rijen “eigenschappen” van games, en als kolommen “effecten” die in de beschrijving van een game voorkwamen.

Volgens een onderzoeker, kunnen eigenschappen en effecten van games als volgt onderscheiden worden:

Eigenschappen: Feitelijke "objectieve" eigenschappen van de game

Effecten: Gevoelsmatige "subjectieve eigenschappen" die de game oproepen.

Om verband tussen de eigenschappen en effecten te onderzoek is data verzameld met beschrijvingen van 156 games. Bij deze games is gekeken of een eigenschap en/of effect in de beschrijving genoemd werd. Elementen in de tabel geven aan hoe vaak een eigenschap en een effect in bij dezelfde game beschrijving voorkwamen.

Doe CA op de tabel.



OPDRACHT 3: PADDESTOELEN

- Open de mushroom data.
- Dit zijn allemaal categorische variabelen over paddestoelen.
- Doe MCA.

